

# Сети глубокого обучения в задачах обнаружения изменения свойств случайных процессов

Е. Н. Бендерская<sup>1</sup>, А. М. Сазанов<sup>2</sup>

Санкт-Петербургский политехнический университет Петра Великого

<sup>1</sup>helen.bend@gmail.com, <sup>2</sup>arseny.sazanov@gmail.com

**Аннотация.** В работе проводится сравнение классических алгоритмов, основанных на математических статистиках для принятия решения о наличии или отсутствии изменения свойств случайного процесса и биоинспирированного подхода на основе нейронных сетей глубокого обучения. Проводится анализ преимуществ нейронных сетей и трудностей, которые присущи новому подходу.

**Ключевые слова:** глубокое обучение; нейронная сеть; изменение свойств случайных процессов; решающая статистика

## I. ВВЕДЕНИЕ

Задача обработки временных рядов возникает во многих практических приложениях. В функциональной диагностике динамических объектов обработка результатов работы информационно-измерительной системы во времени трансформируется в поиск моментов изменения свойств временного ряда – переключение с одной модели, связанной с нормальным функционированием ИИС, на другую модель, связанную с возникновением дефекта [1].

Особенность такой постановки задачи заключается в необходимости определить момент переключения «как можно скорее». Формализация в этом случае приводит к задаче о разладке – наискорейшее обнаружение изменения свойств случайного процесса. При классическом подходе к решению такой задачи используются последовательные методы, как правило, опирающиеся на решающие статистики [2, 3, 4]. С учетом необходимости решения задачи в реальном времени и потребности в обнаружении даже небольших отклонений от базовой модели нормального функционирования, может быть предложено ряд решений на основе нейросетевого подхода [1, 5].

## II. НЕЙРОННЫЕ СЕТИ ПРЯМОГО РАСПРОСТРАНЕНИЯ И ЗАДАЧА О РАЗЛАДКЕ

Первые попытки применения нейронных сетей прямого распространения привели к распараллеливанию общего алгоритма принятия решения, но не позволили значительно улучшить показатели качества обнаружения – значительного сокращения среднего числа шагов запаздывания в обнаружении разладки при фиксированном уровне вероятности ложного обнаружения достичь не удалось.

Были рассмотрены и реализованы разные варианты формирования нейросетевой структуры с учетом разных вариантов постановки задачи функциональной диагностики ИИС [1].

Некоторые результаты моделирования нейросетевых структур и соответствующие характеристика качества обнаружения в зависимости от величины разладки представлены на рис. 1.

В последнем случае (нейронная сеть прямого распространения с несколькими скрытыми слоями, обученная на выборках нормального функционирования и функционирования с минимально обнаруживаемой разладкой вида «сдвиг математического ожидания», соответствующего техническим требованиям) можно говорить о реализации алгоритма с обобщенными решающими статистиками и многопороговой системе принятия решений.

Из характеристического кривого обнаружения видно, что с помощью обучения сеть прямого распространения может быть настроена на требуемую вероятность ложного обнаружения и при этом обеспечивать лучшее время запаздывания в обнаружении малых разладок как по математическому ожиданию, так и по дисперсии.

## III. СЕТИ ГЛУБОКОГО ОБУЧЕНИЯ И ЗАДАЧА О РАЗЛАДКЕ

Успешное применение сетей глубокого обучения для решения задач распознавания статических образов закономерно приводит к желанию применить такой подход для решения задач о разладке. В этом случае для обучения и тестирования, так же, как и для случая сетей прямого распространения, необходимо создание наборов обучающих и тестовых последовательностей из временного ряда путем сдвига окошек наблюдения.

В данной работе за основу взята базовая модель свёрточной нейронной сети (CNN) для 10 классового классификатора изображений набора данных CIFAR-10 [6]. Ее структура представлена на рис. 2.

Основу структуры составляют:

- входной слой (input layer);
- слой свертки (convolution layer);
- слой субдискретизации (max pooling);

- полносвязный скрытый слой (flatten);
- выходной слой (output layer).





Рис. 1. Характеристики обнаружения разладки а) вида «изменение математического ожидания», б) вида «изменение дисперсии»

В качестве активации в слое свертки и скрытом слое используется линейная функция активации «Relu». Для выходного слоя используется функция логистическая функция активации «Softmax».

С учетом особенностей поставленной задачи обнаружения разладки случайных процессов были введены изменения в архитектуру:

- уменьшено число классов до 2 (классификация производилась по признаку наличия разладки);
- использованы одномерные слои свертки и субдискретизации (Conv1D и MaxPooling1D), так как размер входного изображения – одномерная последовательность (т.е. вектор);

- с учетом склонности CNN к переобучению [7] сразу были добавлены слои Dropout для препятствия переобучению (их задача исключать случайное число нейронов из процесса обучения).

Полученная структура сети представлена на рис. 3.

#### А. Средства программной реализации CNN

Для реализации данной задачи было выбрано следующее программное обеспечение:

- язык программирования Python. Библиотеки matplotlib, numpy;
- открытая нейросетевая библиотека Keras [8], написанная на Python, представляющая собой высокоуровневую надстройку над фреймворками для машинного обучения: TensorFlow, Theano и др.;
- в качестве бэкенда для Keras был выбран TensorFlow [9];
- среда разработки Pycharm IDE (Education).

#### В. Обучение и тестирование модели

Для обучения модели нейронной сети были выбраны следующие параметры. Объем обучающей и тестовой выборок составили по 200 000 последовательностей. Длина одной последовательности составляла  $T=20$ . Каждая последовательность делилась на  $N$  окошек по  $M=10$  отсчетов, которые подавались на вход нейронной сети. Соответственно  $N=T-M=10$ , общий объем тестовой выборки 2 млн. окон. Время возникновения разладки – случайная величина в диапазоне  $t = (M:T)$ .

Соотношение последовательностей с разладкой к последовательностям без разладки было выбранным 1 к 1, соотношение окошек с разладкой к окошкам без разладки также было выбрано 1 к 1, это обусловлено метрикой качества обучения – точность классификации по классам.

Метрика для ошибки – «categorical crossentropy». Оптимизатор - «SGD»,  $lr=0.001$ . Количество эпох обучения равно 100. Для раннего останова обучения (EarlyStopping on) использовано значение равное 25. Обучение модели проходило на CPU (ПК Intel Core I-7 2600K, RAM 32 Gb.). Одна эпоха длилась 100 секунд.

#### С. Результаты моделирования

В ходе экспериментов были получены следующие результаты по вероятности обнаружения разладки для разладки величиной  $M=1$  (сдвиг математического ожидания) – 62% (точность Accuracy).

После постобработки окошек для последовательностей получены следующие показатели качества обнаружения разладки:

- обнаружение разладки без запаздывания (в момент возникновения) 6.7%;
- обнаружение разладки после возникновения разладки с запозданием 27.4%;

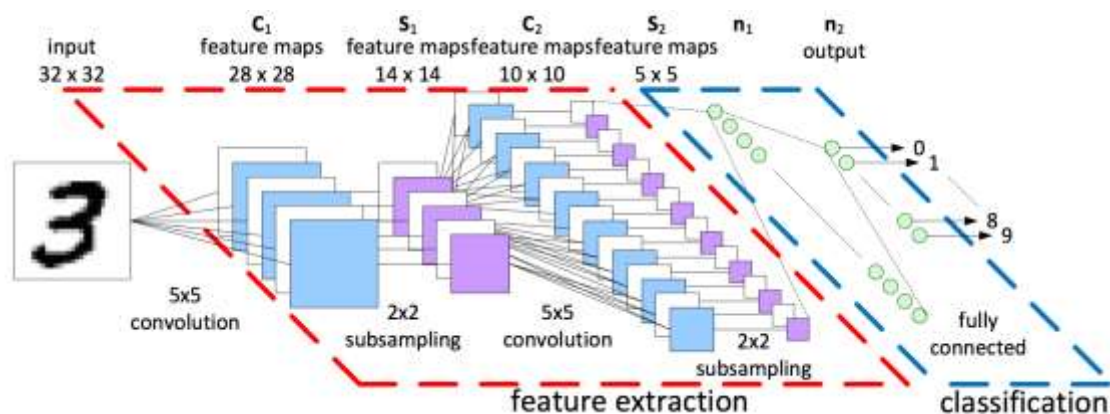


Рис. 2. Базовая модель CNN для решения задачи классификации изображений на 10 классов [6]




Рис. 3. Рис. 3 Архитектура исследуемой сверточной нейронной сети для задачи обнаружения разладки

- ложное обнаружение разладки 44.8%;
- верное не обнаружение разладки 21.1%.

Сеть продемонстрировала хорошие показатели по обнаружению разладки: среднее время обнаружения составило 1.37 (дисперсия 3.75). Однако этот результат портит очень высокая вероятность ложного обнаружения.

Сеть имеет склонность к переобучению, так для обучаемой выборки сеть при обучении показывала более 95%, однако на тестовой она составила не более 55%. Сеть чувствительна к распределению классов в обучающих данных. Стоит отметить что обучающая выборка имела относительно небольшой объем с учетом сложности данной задачи и есть еще дополнительные возможности по оптимизации базовой структуры для конкретной задачи. Планируется использование GPU для обсчета нейронной сети, а также увеличение объема выборки и усложнение модели в глубину.

Продемонстрирована принципиальная возможность решения задачи о разладке с использованием сверточных нейронных сетей, и при усложнении сети и расширении

обучающей выборки можно достичь значительно лучших результатов.

Дальнейшие исследования планируется выполнить по нескольким направлениям:

- Объединение нескольких моделей каждая из которых будет настроена отдельно.
- Усложнение текущей модели – увеличение размера окна и увеличение модели в глубину.
- Изменение формата входа, замена вектора на массив векторов из окон, смещенных по времени.
- Преобразование данных в другую форму, например, синтетическое изображение и его предобработка) или представление данных в другой форме (например, смена системы координат на полярную).

#### IV. ЗАКЛЮЧЕНИЕ

Достоинство подхода на основе сетей глубокого обучения – большое разнообразие архитектур, которые при правильном подборе позволяют решить задачи функциональной диагностики в разных постановках – как обнаружение разных типов разладки (математического ожидания и дисперсии, а в перспективе и коэффициента авторегрессии), так и локализации разладки и обнаружение восстанавливаемых разладок.

Особенности метода обнаружения на основе рассмотренной сети глубокого обучения – вероятность обнаружения разладки практически не зависит от ее величины, как следствие и время запаздывания в обнаружении разладки также практически не зависит от ее величины. Эту особенность можно использовать в дальнейшем для настройки обнаружения малых разладок.

Один из основных недостатков сетей глубокого обучения – неуниверсальность структур и отсутствие научно обоснованных рекомендаций для подбора структуры. Кроме того, практически нет самообучающихся структур, только обучение с учителем или с критиком, что не позволяет добиться хорошей адаптивности при смене ситуации и необходимости расширения функциональных возможностей.

#### СПИСОК ЛИТЕРАТУРЫ

- [1] Бендерская Е.Н., Колесников Д.Н., Пахомова В.И. Функциональная диагностика систем управления. СПб.: СПбГТУ, 2000. 144 с.
- [2] Qi J.-P., Qi J., Zhang Q. A Fast Framework for Abrupt Change Detection Based on Binary Search Trees and Kolmogorov Statistic. *Computational Intelligence and Neuroscience*, vol. 2016, Article ID 8343187, 16 pages, 2016. <https://doi.org/10.1155/2016/8343187>.
- [3] Alippi C., Boracchi G., Roveri M. Hierarchical Change-Detection Tests. *IEEE Transactions on Neural Networks and Learning Systems*, vol. 28, Issue: 2, pp. 246-258, 2017.
- [4] Volkhonskiy D., Burnaev E., Nourtdinov I., Gammernan A., Vovk V. Inductive conformal martingales for change-point detection. *Proceedings of Machine Learning Research* 60, pp. 132-153, 2017.
- [5] Benderskaya E.N. Nonlinear Trends in Modern Artificial Intelligence: A New Perspective. *Beyond AI: Interdisciplinary Aspects of Artificial Intelligence. Topics in Intelligent Engineering and Informatics*, Springer, vol.4, pp. 113-124, 2013.
- [6] Peemen M., Mesman B., Corporaal H. Efficiency optimization of trainable feature extractors for a consumer platform. *Proceedings of the 13th International Conference on Advanced Concepts for Intelligent Vision Systems*, Springer, pp. 293-304, 2011.
- [7] Wan Li, Zeiler Matthew, Zhang Sixin, Le Cun Yann, Fergus Rob Regularization of Neural Networks using DropConnect. *Proceedings of the 30th International Conference on Machine Learning, PMLR* 28(3), pp.1058-1066, 2013.
- [8] Keras: The Python Deep Learning library [Электронный ресурс] / Официальный сайт библиотеки «Keras». — Режим доступа : <https://www.keras.io/> (дата обращения : 21.05.18).  
About TensorFlow [Электронный ресурс] / Официальный сайт фреймворка «Tensorflow». — Режим доступа : <https://www.tensorflow.org/> (дата обращения : 21.05.18).